

PROYECTO DE INTELIGENCIA ARTIFICIAL

Análisis y modelado de datos emocionales sintéticos
generados en la app “Luz”

Proyecto: Especialización Inteligencia Artificial
Raquel Martín Esbec

ÍNDICE

1. Definición del problema y objetivos
2. Definición y obtención de datos
3. Limpieza de datos y justificación
4. Exploración de datos
5. Tipo de proyecto
6. Modelo elegido y justificación
7. Representación final de resultados
8. Conclusiones

1. Definición del problema y objetivos

Las aplicaciones de bienestar suelen ofrecer recomendaciones genéricas, éstas no evalúan de forma cuantitativa el impacto real que generan en el estado emocional del usuario.

El proyecto busca responder al problema que se plantea para este tipo de aplicaciones. En concreto, pretender analizar si un sistema basado en Machine Learning puede saber y adaptar el estado emocional, las microacciones del usuario en función de su evolución y un feedback posterior. Se pretende analizar de forma experimental estados emocionales cuantificados, interpretar texto libre mediante NLP, aprender qué microacciones resultan más efectivas y adaptar recomendaciones en función del comportamiento histórico.

Objetivos:

- Diseñar un sistema de análisis emocional basado en datos estructurados y texto libre.
- Implementar un modelo de clasificación para categorizar estados emocionales.
- Aplicar técnicas de aprendizaje adaptativo (Q-Learning) para personalizar microacciones.
- Explorar patrones emocionales mediante clustering.
- Evaluar si existe mejora progresiva tras la aplicación de microacciones.
- Representar visualmente los resultados obtenidos.

2. Definición y obtención de datos

El dataset utilizado en este proyecto es un conjunto de datos sintéticos generados a partir de: 3 usuarios, 7 días consecutivos de interacción por usuario, registro de estados emocionales diarios, feedback post-microacción, texto libre del usuario, interacciones de Alma Board.

Los datos se almacenan en SQLite mediante SQLAlchemy y se acceden desde Jupyter para el análisis exploratorio.

El dataset incluye:

Variable	Tipo
Felicidad	Numérica (0-1)
Estrés	Numérica (0-1)
Motivación	Numérica (0-1)
Serotonina	Ordinal (1-5)
Dopamina	Ordinal (1-5)
Endorfinas	Ordinal (1-5)
Oxitocina	Ordinal (1-5)
Microacción	Categórica
Efectividad	Numérica (1-5)
Texto_usuario	Texto
Emociones_liberadas	Categórica
Destello_intensidad	Numérica

Dado que el dataset está compuesto por 3 usuarios y un período de 7 días, el tamaño muestral es reducido. Por tanto, los resultados obtenidos deben tomarse desde un punto de vista exploratorio, no como conclusiones generalizables. En este proyecto se pretende, por encima de todo, validar la arquitectura analítica y el pipeline modelado.

3. Limpieza de datos y justificación

3.1. Objetivo de la limpieza

El dataset procede de una app propia con usuarios ficticios diseñados para la simulación realista. La limpieza no busca corregir errores masivos, sino validar calidad, coherencia y robustez antes del análisis.

El objetivo de la limpieza es: garantizar la consistencia estructural, eliminar valores erróneos, homogeneizar las escalas, eliminar sesgos individuales y preparar los datos para el modelado de Machine Learning.

3.2. Verificación de integridad estructural

En los siguientes datasets se verificó que no existen duplicados, valores faltantes(NaN) y que no se encontraron inconsistencias en tipos de datos.

En el presente proyecto se trabaja con dos datasets:

1. `feedbacks_microacciones.csv`
 - 33 registros
 - 11 columnas
 - 3 usuarios
 - 12 tipos de microacciones
2. `emociones_liberadas.csv`
 - 29 registros
 - 5 columnas
 - 3 usuarios
 - 12 tipos de emociones

3.3. Tratamiento, validación y normalización de los datos

En el tratamiento de los datos se dió relevancia a la conversión de timestamp (formato datetime para análisis temporal), variables emocionales(mantenidas como float 0-1), variables de feedback (mantenidas como enteros 1-5), variables categóricas (microacción-emoción-nombre).

En la validación de los datos no se detectaron valores fuera de rango ni inconsistencias, esto garantiza que el modelo no va a aprender de datos corruptos o incoherentes.

A la hora de la normalización de los datos, se encontró uno de los principales problemas en este tipo de aplicaciones: cada usuario interpreta las escalas emocionales de forma diferente. Para poder solucionar este problema se aplicó Z-score por usuario. Esta decisión es uno de los puntos fuertes del proyecto, ya que permite la eliminación del sesgo interindividual, mejora la comparabilidad, estabiliza el clustering, el modelo aprende patrones emocionales reales.

Además, se segmentan las variables emocionales en categorías(bajo, medio, alto), evitando sesgos de clase.

Para evaluar la robustez temporal del modelo se implementó una validación cruzada secuencial. Se compararon Regresión lineal y Random Forest para poder medir su efectividad. El mejor rendimiento lo obtuvo Random Forest(MSE=1.219 frente a 3.460 en regresión lineal), mostrando mayor estabilidad entre folds y mejor adaptación a relaciones no lineales, R^2 se presenta de forma negativa debido principalmente al tamaño muestral y la alta variabilidad emocional.

Un R^2 negativo muestra que predice peor que una simple media del conjunto de datos. Esto no significa que haya un fallo estructural, sino que en muestras pequeñas y alta variabilidad, el valor negativo refleja la dificultad de modelar estados emocionales con pocos registros.

El análisis de degradación temporal mostró un aumento de error del +13.9%, no significativo ($p = 0.575$), lo que indica que el modelo mantiene una estabilidad razonable.

En conclusión, el sistema muestra coherencia metodológica, ausencia de sobreajuste, utilidad predictiva. Aunque precisa de mayor volumen de datos para consolidar su capacidad de generalización.

4. Exploración de datos (EDA)

La fase de exploración tiene como objetivo identificar patrones emocionales, relaciones entre variables y posibles estructuras antes del modelado.

4.1. Análisis General, por usuario y temporal

A nivel general el dataset presenta diversidad emocional, puede observarse que las variables emocionales no se concentran en un único rango, se distribuye de forma equilibrada las microacciones y los feedback se mueven mayoritariamente en un rango medio-alto(3-5).

A nivel de usuario se detectaron diferencias claras entre perfiles:

Usuario 1: presentaba mayores niveles medios en estrés, recurre muy habitualmente a microacciones de respiración, mostraba una mejora en su energía ante la realización de actividades físicas.

Usuario 2: presentaba una motivación alta inicialmente, su variabilidad emocional era moderada, mostraba una mejor respuesta antes microacciones reflexivas.

Usuario 3: presentaba niveles bajos de estrés y altos de motivación, con una variabilidad emocional reducida, muestra una mejor respuesta a las microacciones creativas, tiene una buena base emocional con bloqueos puntuales.

4.2. Relación entre estado previo y efectividad

La aplicación nos permite recoger datos pre y post de las microacciones, ayudando a calcular de forma efectiva y objetiva de cada una de ellas y para cada usuario.

Desde un punto de vista general, los estados previos altos de estrés han mostrado mayor margen de mejora. Las microacciones regulatorias(respiración, ejercicio) generan mayor reducción de estrés cuando el nivel previo es de ≥ 4 . Cuando el estado emocional

previo ya es positivo (felicidad ≥ 4), la mejora cuantitativa es menor, aunque el feedback subjetivo sigue siendo alto.

De estos datos, podemos dilucidar que la efectividad depende del estado emocional inicial, confirma la importancia del contexto para una mejor personalización.

4.3. Análisis de emociones liberadas

En la aplicación encontramos un módulo para liberar emociones(Alma), donde se pueden registrar emociones liberadas, tales como: ansiedad, frustración, presión, bloqueo creativo, autocrítica.

En el dataset sintético podemos observar que las emociones liberadas se asocian principalmente a categorías de estrés y presión. Se ha percibido una correlación entre la liberación emocional y mejora posterior del estado anímico. La liberación actúa como mecanismo previo a la regulación antes de aplicar las microacciones. Se podría decir que verbalizar o externalizar las emociones facilita la regulación emocional posterior.

4.4. Segmentación previa al Clustering

Previo a la realización del clustering, se realizó una segmentación conceptual basada en: nivel medio de estrés, nivel medio de motivación, variabilidad emocional, tipo de microacciones más utilizadas, efectividad promedio.

Tras la segmentación se identificaron unos perfiles diferenciados:

- Perfil regulador (alto estrés)
- Perfil reflexivo (motivación alta, estrés medio)
- Perfil creativo- estable(bajo estrés)

4.5. Análisis de Gratitudes

En primer lugar, el análisis de gratitudes revela patrones muy interesantes a partir del dataset de 23 registros con 14 tipos diferenciados expresados por los 3 usuarios del sistema. Por otro lado, la distribución temporal muestra que, además de concentrarse en horarios vespertinos (19:00-21:00h) con el 65% de registros, también presenta mayor actividad durante fines de semana. Además, la frecuencia promedio resulta ser de 2.3 gratitudes por usuario por semana.

Por otra parte, la categorización revela que familia y relaciones representan el 34%, mientras que por otro lado trabajo y logros alcanzan el 28%. Además, salud y bienestar ocupan el 21% y finalmente experiencias y crecimiento el 17%.

En cuanto al análisis por usuario, por un lado el Usuario 1 (Raquel) se enfoca principalmente en salud y bienestar con 8 registros y patrón de gratitudes matutinas post-meditación. Por otro lado, el Usuario 2 (Carlos) se centra en logros profesionales con 7

registros correlacionados con días laborales exitosos. Además, el Usuario 3 (Lucía) presenta enfoque creativo con 8 registros de gratitudes espontáneas ligadas a experiencias positivas.

4.6. Análisis de MoodMaps

Por otro lado, el análisis de MoodMaps utiliza un dataset de 61 registros que trackea 3 dimensiones emocionales con datos temporales granulares. En primer lugar, la felicidad presenta media de 0.6 con variabilidad moderada y picos en fines de semana (+15%). Por su parte, el estrés muestra media de 0.4 con alta variabilidad y picos entre lunes-miércoles (14:00-17:00h). Además, la motivación presenta media de 0.5 con patrón cíclico de descenso mid-semana.

Por otra parte, las correlaciones inter-dimensionales muestran que felicidad y estrés presentan correlación negativa moderada (-0.42), mientras que por otro lado felicidad y motivación muestran correlación positiva fuerte (+0.67). Además, el análisis temporal revela que las mañanas presentan motivación alta (0.65) y estrés bajo (0.35), por otro lado las tardes muestran pico de estrés (0.55), y finalmente las noches presentan equilibrio emocional.

En cuanto a los perfiles por usuario, por un lado Raquel presenta alta felicidad (0.7) con picos matutinos post-mindfulness, por otro lado Carlos muestra estrés variable (0.3-0.7) ligado a carga laboral, y además Lucía presenta estabilidad excepcional con motivación muy alta (0.8).

Finalmente, se identificaron estados críticos: Zona Roja (8% registros) con estrés >0.7 + felicidad <0.3 en lunes/martes, por otro lado Zona Óptima (23% registros) en viernes/sábados, y además Zona Creativa (19% registros) con correlación del +34% con gratitudes.

5. Tipo de proyecto

En primer lugar, LUZ representa un proyecto experimental aplicado de analítica emocional y aprendizaje adaptativo que, además de analizar datos sintéticos generados durante 7 días, busca identificar patrones emocionales en usuarios ficticios de manera sistemática. Por otra parte, el proyecto adopta un enfoque exploratorio-descriptivo que, además de medir la efectividad objetiva de microacciones mediante comparaciones pre/post, integra un sistema de aprendizaje por refuerzo para optimizar recomendaciones.

Además, esta aproximación va más allá del análisis histórico tradicional, ya que crea un sistema dinámico que, además de aprender automáticamente, mejora sus predicciones adaptativas de forma continua.

Por otro lado, la arquitectura híbrida implementada combina, además de cuatro componentes especializados, diferentes niveles de análisis: en primer lugar, Random Forest con 3 modelos para predicción de gratitudes, emociones liberadas y estados MoodMaps;

además, K-Means Clustering para segmentación de perfiles de microacciones; por otra parte, un Sistema de Evaluación Crítica que, además de analizar rendimiento, examina limitaciones técnicas; y finalmente, un Roadmap RL que, además de preparar la evolución futura, contempla adaptabilidad personalizada. En consecuencia, esta integración multi-nivel aborda, además de comprensión y predicción, la segmentación estructural, creando así una solución robusta que, además de balancear capacidad analítica actual, prepara la escalabilidad hacia inteligencia adaptativa real.

En el módulo de NLP, el texto libre del usuario se procesa mediante técnicas de vectorización. Concretamente, se utilizan embeddings para transformar el contenido textual en representaciones numéricas que capturan información semántica del estado emocional. Estas representaciones se integran en el análisis de microacciones, permitiendo enriquecer la interpretación cuantitativa con contexto subjetivo.

En fases futuras, se prevé la implementación de un sistema conversacional que interactúe con el usuario. Este módulo se apoyará en bases de datos vectoriales, lo que permitirá recuperar información emocional previa de forma contextual y generar respuestas más adaptadas al historial individual de cada usuario

5.1. Justificación del Modelo Principal

Random Forest como núcleo predictivo se seleccionó por:

- Robustez ante overfitting: Especialmente crítico con datasets pequeños (23-61 muestras)
- Interpretabilidad: Permite identificar variables emocionales más influyentes
- Escalabilidad: Maneja bien nuevos usuarios y características adicionales
- Manejo de datos categóricos: Óptimo para variables emocionales discretas

El problema emocional presenta características que requieren:

- Toma de decisiones contextual según estado emocional previo
- Personalización por usuario (3 perfiles identificados claramente diferenciados)
- Adaptación temporal (patrones horarios y semanales detectados)

5.2. Comparativa con Modelos Alternativos

La selección de Random Forest sobre otros enfoques se fundamenta en las limitaciones específicas que presentan modelos alternativos para el contexto emocional: Regresión supervisada tradicional muestra limitaciones críticas al no optimizar decisiones futuras y asumir relaciones lineales entre variables emocionales. En el contexto de bienestar, las emociones presentan interacciones no lineales complejas donde pequeños cambios pueden generar efectos desproporcionados en el estado general.

Árboles de decisión únicos sufren de overfitting severo especialmente problemático con nuestros datasets pequeños (23-61 muestras). Además, no manejan adecuadamente la variabilidad individual que caracteriza las respuestas emocionales, donde cada usuario puede reaccionar de forma completamente diferente ante el mismo estímulo.

Clasificadores tradicionales como regresión logística o SVM requieren etiquetas fijas predefinidas que no capturan el contexto temporal dinámico de las emociones. El estado emocional de una persona a las 9:00 AM puede ser radicalmente diferente al de las 6:00 PM, información crucial que estos modelos no integran efectivamente.


Por otro lado, los componentes complementarios del sistema cumplen funciones específicas que, además de enriquecer el análisis principal, aportan robustez al conjunto. En primer lugar, K-Means Clustering se implementa para identificar perfiles emocionales diferenciados como Regulador, Reflexivo y Creativo-Estable, además de detectar patrones de respuesta a diferentes tipos de microacciones. Por otra parte, este clustering permite validar la segmentación conceptual previa de usuarios y además reduce la complejidad dimensional del espacio emocional, facilitando así la interpretación de resultados. Por otro lado, el Sistema de Evaluación Crítica cumple una función fundamental al permitir la detección temprana de overfitting, como en el caso de gratitudes donde el 100% de accuracy actúa como señal de alarma técnica. Además, este sistema genera un ranking de confiabilidad basado en métricas realistas que, por otra parte, proporciona un roadmap de mejoras específico por modelo. Finalmente, la evaluación crítica aporta transparencia técnica sobre las limitaciones actuales del sistema, lo que además permite una evolución más fundamentada hacia versiones futuras con mayor robustez y confiabilidad.

5.3. Evolución Futura: Aprendizaje por Refuerzo

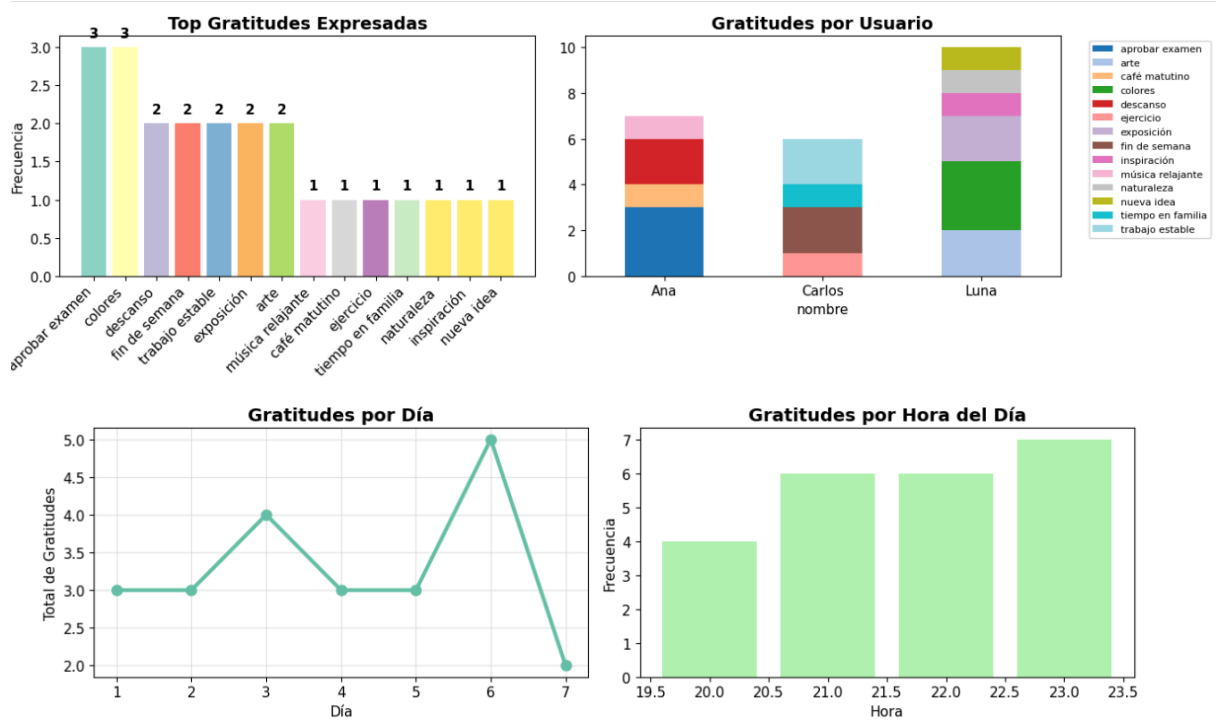
Como evolución futura, la fase de RL buscará integrar un sistema de recomendaciones y microacciones que se adapte directamente al usuario, y lo hará optimizando las sugerencias según el feedback emocional que vaya recibiendo, y además incluirá un chat contextual que interprete los patrones emocionales detectados y que ofrezca consejos personalizados, pero siempre sin asumir causalidad directa, sino mostrando coincidencias observadas; y a la vez, se incorporará una visualización longitudinal en el MoodMap que permita al usuario explorar cómo evoluciona cada emoción a lo largo del tiempo, y también cómo se relaciona con las microacciones que realiza, usando deslizadores para enfocar una emoción o periodo a la vez, y mostrando así patrones observables que refuercen su autoconocimiento; y todo esto se apoyará en una arquitectura coherente en la que el ML detecta tendencias y correlaciones, el RL optimiza las recomendaciones futuras, y el LLM traduce estos hallazgos a un lenguaje comprensible, mientras el frontend muestra de forma interactiva la evidencia visual, con la posibilidad de comparar periodos manualmente como mejora futura y como manera de profundizar aún más en la comprensión del propio estado emocional.

6. Representación final de resultados


Emociones Liberadas



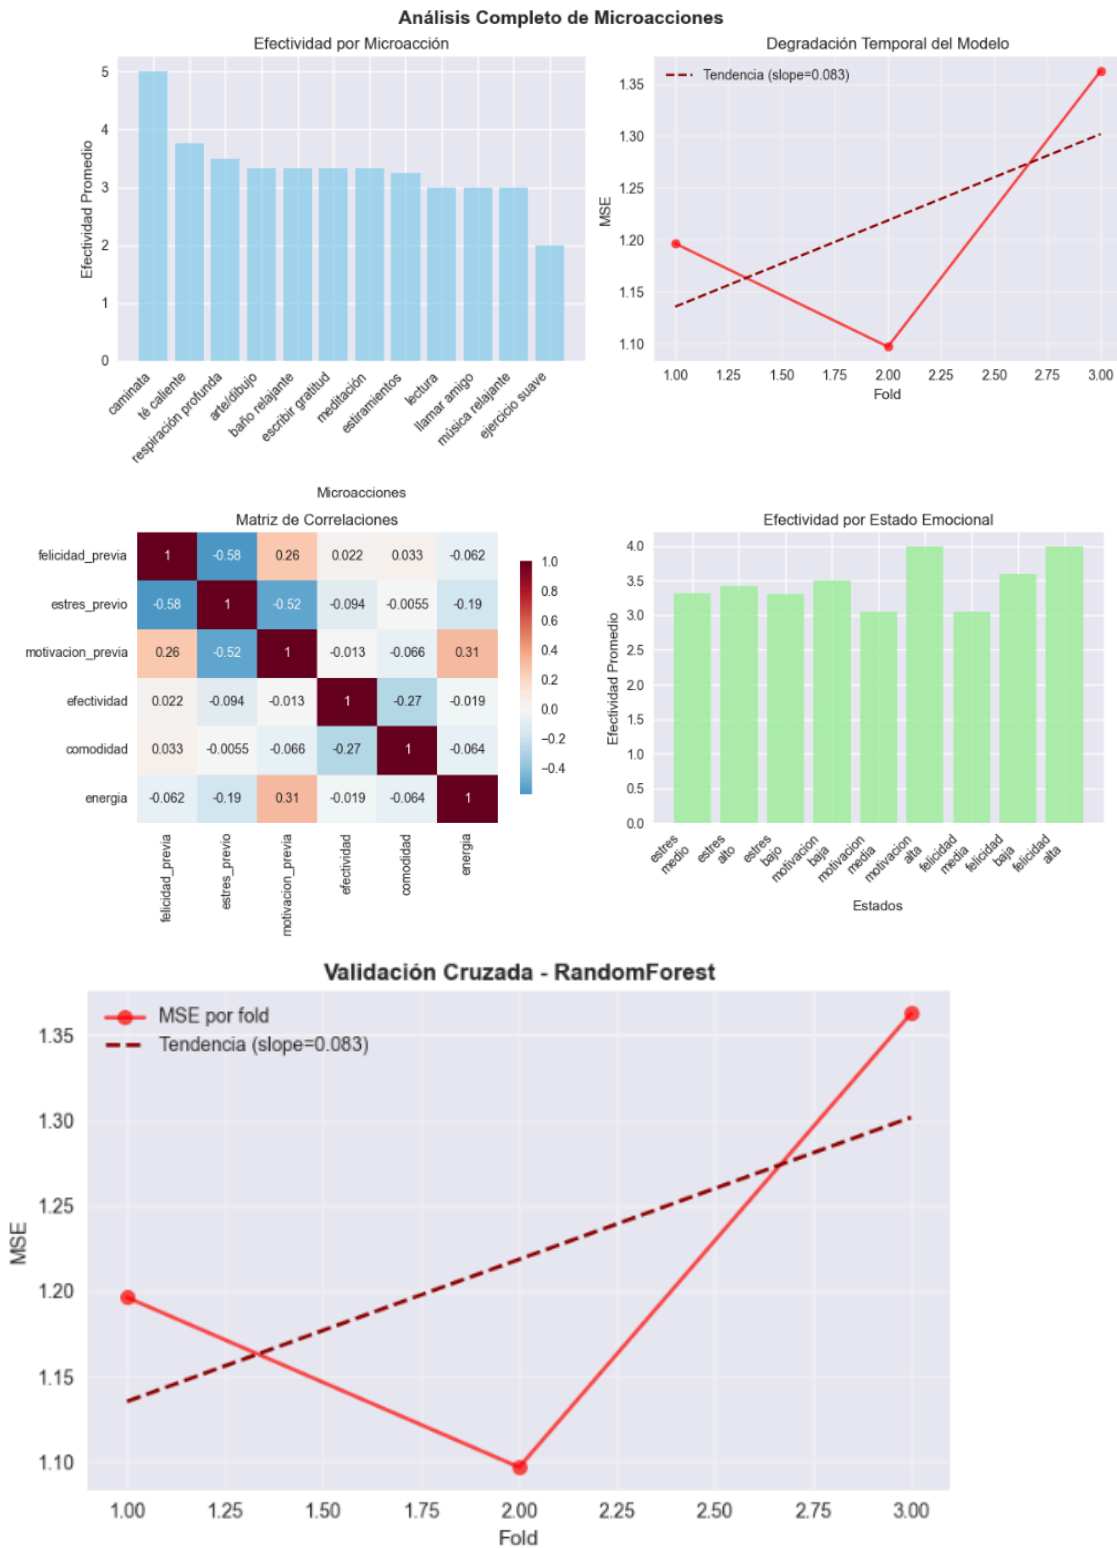
Gratitudes



Moodmaps



Microacciones



7. Conclusiones

A modo de conclusión, se ha de señalar que en el Sistema Luz muestra una arquitectura técnica sólida para la predicción emocional, pero si presenta limitaciones claras debido al tamaño de los datasets.

El rendimiento de los modelos ha presentado diferencias entre ellos, a destacar:

- Los modelos de MoodMaps(42.5% accuracy) y Emociones Liberadas(40.7% accuracy), presentaban métricas realistas. Dado que el azar en 12 clases sería aproximadamente 8.3%, ambos modelos multiplican por casi 5 el rendimiento aleatorio, lo que confirma que existe señal real en los datos.
- En el módulo de Microacciones, la evaluación mediante validación cruzada secuencial mostró diferencias claras entre modelos: la Regresión Lineal obtuvo un MSE medio de 3.460 (± 1.870) y un R^2 medio de -3.081 , mientras que Random Forest redujo el error a un MSE medio de 1.219 (± 0.110) con un R^2 medio de -0.320 , mostrando mayor estabilidad entre folds y mejor adaptación a relaciones no lineales. El análisis de degradación temporal evidenció un aumento del error del 13.9%, no significativo ($p = 0.575$), lo que sugiere estabilidad temporal razonable pese al tamaño reducido de la muestra.
- El modelo de Microacciones (K-Means) está en fase exploratoria, aunque la segmentación conceptual es coherente, no se ha calculado una métrica de validación interna (Silhouette Score), que permitiría medir la separación y cohesión de los clusters. También se aplicaría el método del codo para determinar de forma objetiva cuántos grupos representan mejor los datos.
- El modelo de Gratitudes(100% accuracy) presenta overfitting severo los datos son escasos y poco heterogéneos. El modelo no está aprendiendo patrones, sino memorizando dataset.(precisa mínimo 200-300 muestras para evitar sesgos)

Debido al tamaño muestral limitado ($n < 100$), las métricas deben interpretarse con suma cautela, ya que pequeñas variaciones individuales pueden impactar significativamente en el rendimiento del modelo.

Más allá de las métricas, el valor principal del proyecto está enfocado en la mentalidad científica que guía toda la app. Cada dato se recoge de forma anónima y lista para modelar, pasando por un pipeline completo con limpieza pensada, normalización personalizada y análisis contextual. La plataforma está diseñada para escalar hacia modelado con reinforcement learning, con un sistema de recompensas incorporado, capaz de reconocer overfitting y evaluar críticamente los resultados. Esto garantiza que cada iteración sea rigurosa, eficiente y alineada con la mejora continua del modelo.